

T.C.
BARTIN ÜNİVERSİTESİ
MÜHENDİSLİK MİMARLIK ve TASARIM FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



BSM357 YAPAY ZEKA DERSİ PROJE RAPORU

Elektrik Transformatörü Yağ Sıcaklığı Tahmini: LSTM, GRU ve Transformer
Mimarilerinin Karşılaştırmalı Analizi

23010310027 BÜŞRA DEMİRKİRAN
23010310028 DOĞA DOĞANAY
23010310069 SUDE SENA TEMİR

Dersin Sorumlusu

DOÇ. DR. HAKAN ÖCAL

Bartın, 2026

İÇİNDEKİLER

1. Model Hakkında Kısa Açıklama	1
2. Tasarlanan Modeli Anlatan Açıklamalar ve Şekiller	1
3. Model ile İlgili Farklı Senaryolar	2
3.1. LSTM Senaryosu.....	3
3.2. GRU Senaryosu.....	4
3.3. Transformer Senaryosu	5
4. Sonuçların Değerlendirilmesi / Karşılaştırma	6
4.1. Ek Deney: 24 Saat Tahmini.....	6
4.2. Genel Yorum	7
5. Veri Seti ve Literatür Araştırması	8
6. Referanslar.....	9

1. Model Hakkında Kısa Açıklama

Bu projede, elektrik transformatörlerinin yağ sıcaklığı değerini tahmin etmek amacıyla üç farklı derin öğrenme mimarisi kullanılmıştır: Long Short-Term Memory (LSTM), Gated Recurrent Unit (GRU) ve Transformer tabanlı model. Çalışmada aynı veri seti üzerinde aynı ön işleme adımları uygulanarak modellerin performansları karşılaştırılmıştır. Amaç, bu üç mimarinin zaman serisi tahmini probleminde doğruluk, kayıp, model karmaşıklığı ve öğrenme davranışı açısından nasıl bir performans sergilediğini incelemektir.

Kullanılan veri seti ETTh1 veri setidir. Bu veri seti, elektrik transformatörüne ait saatlik ölçümler içermekte olup hedef değişken olarak yağ sıcaklığı (OT) kullanılmaktadır. Modeller, geçmiş zaman adımlarındaki verileri kullanarak bir sonraki zaman adımındaki OT değerini tahmin edecek şekilde eğitilmiştir. Bu amaçla, veri üzerinde train-validation-test ayrımı yapılmış, ölçekleme uygulanmış ve sliding window yöntemi ile giriş-çıkış çiftleri oluşturulmuştur. Ortak ön işleme yaklaşımının kullanılması sayesinde modellerin performansları daha adil biçimde kıyaslanabilir hale getirilmiştir. Bu yaklaşım, hocanın örnek raporunda da vurgulanan “aynı veri ve aynı eğitim kurgusu ile adil karşılaştırma” mantığıyla uyumludur.

Yağ sıcaklığının transformatör çalışma durumu için kritik bir gösterge olması nedeniyle bu problem pratik açıdan önem taşımaktadır. Literatürde de transformer oil temperature prediction probleminin güvenlik ve işletme açısından anlamlı olduğu vurgulanmaktadır. Ayrıca ETTh1/ETT-small veri ailesi benzer çalışmalarda da kullanılmıştır.

2. Tasarlanan Modeli Anlatan Açıklamalar ve Şekiller

Bu çalışmada üç farklı zaman serisi tahmin modeli kullanılmıştır: LSTM, GRU ve Transformer. Tüm modeller aynı giriş verileriyle beslenmiş ve aynı hedef değişkeni tahmin edecek şekilde yapılandırılmıştır. Girdi olarak geçmiş **96 saatlik** zaman penceresi kullanılmış, çıktı olarak ise bir sonraki saatlik yağ sıcaklığı (OT) değeri tahmin edilmiştir. Elde edilen veri şekli $X_{train} = [\text{örnek_sayısı}, 96, 7]$ biçimindedir. Bu yapı, her örnekte 96 zaman adımı ve her zaman adımında 7 özellik bulunduğunu göstermektedir. Bu yapılar arasındaki ortak veri işleme süreci aşağıdaki şekil ile özetlenmiştir.

LSTM Modeli

LSTM modeli sıralı veriyi zaman boyunca işleyerek geçmiş bilgiyi hafızasında taşımaya amaçlar. Bu mimari özellikle uzun bağımlılıkları öğrenmek için geliştirilmiştir. Modelde LSTM katmanları kullanılmış ve son zaman adımından elde edilen temsil doğrusal katmana verilerek OT tahmini üretilmiştir.

GRU Modeli

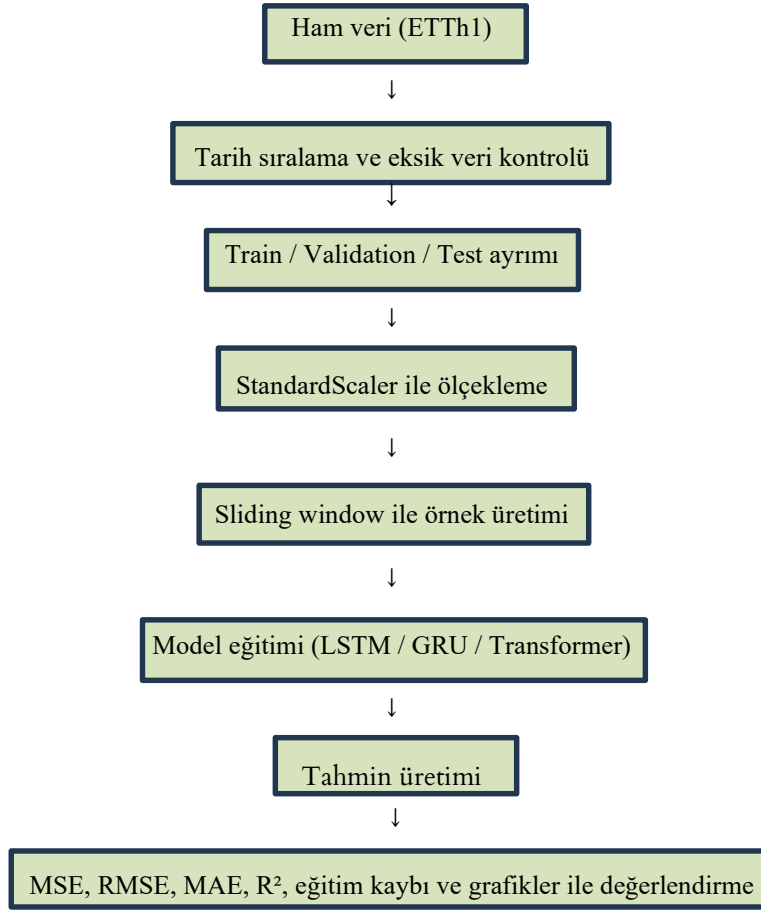
GRU modeli, LSTM’e benzer şekilde sıralı veriyi işler; ancak daha sade bir kapı yapısına sahiptir. Bu nedenle parametre sayısı daha düşük olabilir. Çalışmamızda GRU modeli aynı giriş verileriyle eğitilmiş, son zaman adımındaki gizli durum üzerinden tahmin üretilmiştir. Literatürde de GRU’nun zaman serisi tahmini ve özellikle oil temperature tahmini için etkili bir model olduğu belirtilmektedir.

Transformer Modeli

Transformer modeli, recurrent yapı kullanmadan attention mekanizması ile zaman adımları arasındaki ilişkileri öğrenir. Özellikle uzun bağımlılıkları yakalama konusunda güçlüdür. Informer gibi Transformer tabanlı çalışmalar, uzun zaman serisi tahmininde klasik Transformer’ın hesaplama maliyetini azaltmayı ve prediction capacity’yi artırmayı amaçlamaktadır.

Ortak model akışı

Aşağıdaki yapı tüm modeller için ortaktır:



Şekil 1. Çalışmada kullanılan ortak veri işleme ve modelleme akışı

3. Model ile İlgili Farklı Senaryolar


Bu projede aynı veri seti ve aynı ön işleme adımları kullanılarak üç farklı derin öğrenme mimarisinin performansı karşılaştırılmıştır. Her senaryoda giriş penceresi, veri ayrımı ve hata metrikleri aynı tutulmuş; böylece karşılaştırmanın mümkün olduğunca adil olması hedeflenmiştir. Örnek raporda da farklı optimizasyon algoritmalarının aynı model ve aynı veri üzerinde kıyaslanmasıyla benzer bir mantık kurulmuştur.

3.1. LSTM Senaryosu


LSTM modeli, zaman serilerinde uzun dönemli bağımlılıkları öğrenebilmek için tercih edilmiştir. Hafıza hücreleri ve kapı mekanizmaları sayesinde geçmiş bilgiyi seçici olarak taşıyabilmektedir. Bu çalışmada LSTM modeli, 96 saatlik pencere boyutu ile hazırlanmış veri üzerinde eğitilmiş ve kısa vadeli tahmin senaryosunda test edilmiştir. Elde edilen sonuçlar aşağıdaki gibidir:

- MSE: 0.006816
- RMSE: 0.082556
- MAE: 0.058212
- R^2 : 0.9570
- Parametre sayısı: 201345

Bu sonuçlar, LSTM modelinin ETTh1 veri seti üzerinde kısa vadeli tahminde yüksek doğruluk sağladığını göstermektedir. Eğitim ve doğrulama kaybı eğrileri incelendiğinde modelin stabil bir öğrenme davranışı gösterdiği görülmüştür. Gerçek ve tahmin edilen değerlerin karşılaştırıldığı grafiklerde de modelin genel eğilimi başarılı şekilde takip edebildiği gözlemlenmiştir.



Şekil 2. LSTM modeli eğitim ve doğrulama kaybı grafiği




Şekil 3. LSTM modeli için gerçek ve tahmin edilen değerlerin karşılaştırılması

3.2. GRU Senaryosu


GRU modeli, LSTM'e benzer şekilde sıralı veriyi işleyen ancak daha sade bir kapı yapısına sahip olan bir mimaridir. Daha az parametre ile çalışabilmesi, GRU'yu daha hafif ve daha hızlı eğitilebilen bir alternatif haline getirmektedir. Bu çalışmada GRU modeli de aynı ön işleme adımları uygulanmış veri üzerinde, 96 saatlik pencere boyutu kullanılarak eğitilmiştir. Kısa vadeli tahmin senaryosunda elde edilen sonuçlar şöyledir:

- MSE: 0.007553
- RMSE: 0.086907
- MAE: 0.064953
- R²: 0.9524
- Parametre sayısı: 39041

GRU modeli, LSTM'e göre daha az parametre kullanmasına rağmen oldukça yakın performans üretmiştir. Bu durum, model karmaşıklığı düşük tutulmak istendiğinde GRU'nun güçlü bir alternatif olabileceğini göstermektedir. Eğitim ve doğrulama kaybı eğrileri, modelin kısa vadeli tahminde belirgin bir overfitting göstermeden öğrenebildiğini ortaya koymuştur.



Şekil 4. GRU modeli eğitim ve doğrulama kaybı grafiği



Şekil 5. GRU modeli için gerçek ve tahmin edilen değerlerin karşılaştırılması

3.3. Transformer Senaryosu


Transformer modeli, recurrent yapı kullanmadan self-attention mekanizması ile zaman adımları arasındaki ilişkileri öğrenmektedir. Bu yaklaşım, özellikle uzun bağımlılıkların bulunduğu zaman serilerinde güçlü bir alternatif oluşturmaktadır. Bu çalışmada kullanılan Transformer modeli, 96 saatlik giriş penceresi ve **pred_len=1** senaryosu ile eğitilmiştir. Kısa vadeli tahmin için elde edilen sonuçlar şu şekildedir:

- MSE: 0.010672
- RMSE: 0.103306
- MAE: 0.078942
- R²: 0.9327
- Parametre sayısı: 69825

Sonuçlara göre Transformer modeli de yüksek doğruluk sağlamış, ancak kısa vadeli tahmin senaryosunda LSTM ve GRU modellerinin gerisinde kalmıştır. Bu durum, Transformer tabanlı yaklaşımların özellikle daha uzun tahmin ufuklarında avantaj sağlayabildiğini belirten literatür ile uyumludur. Kısa vadeli ve görece küçük veri yapılarında recurrent modeller daha güçlü performans göstermiştir.



Şekil 6. Transformer modeli eğitim ve doğrulama kaybı grafiği



Şekil 7. Transformer modeli için gerçek ve tahmin edilen değerlerin karşılaştırılması

4. Sonuçların Değerlendirilmesi / Karşılaştırma

Bu çalışmada ETTh1 veri seti kullanılarak LSTM, GRU ve Transformer modellerinin transformatör yağ sıcaklığı tahmini üzerindeki performansları karşılaştırılmıştır. Tüm modeller için aynı veri ayrımı, aynı ölçekleme yaklaşımı ve aynı pencere boyutu kullanılarak adil bir deney ortamı oluşturulmuştur. Kısa vadeli tahmin (**pred_len=1**) sonuçları aşağıdaki tabloda özetlenmiştir:

Model	MSE	RMSE	MAE	R ²	Parametre Sayısı
LSTM	0.006816	0.082556	0.058212	0.9570	201345
GRU	0.007553	0.086907	0.064953	0.9524	39041
Transformer	0.010672	0.103306	0.078942	0.9327	69825

Tablo 1. LSTM, GRU ve Transformer modellerinin pred_len=1 senaryosundaki karşılaştırmalı performans sonuçları

4.1. Ek Deney: 24 Saat Tahmini

Çalışmada yalnızca kısa vadeli tahmin değil, ek deney olarak orta vadeli tahmin senaryosu da incelenmiştir. Bu amaçla **pred_len=24** alınarak modellerin sonraki 24 saatlik yağ sıcaklığı değerlerini tahmin etme performansı gözlemlenmiştir. Elde edilen sonuçlar aşağıdaki gibidir:

Model	MSE	RMSE	MAE	R ²	Parametre Sayısı
LSTM	0.092323	0.303846	0.236403	0.4181	53016
GRU	0.054781	0.234054	0.173269	0.6547	40536
Transformer	0.060233	0.245423	0.187084	0.6203	70584

Tablo 2. LSTM, GRU ve Transformer modellerinin pred_len=24 senaryosundaki karşılaştırmalı performans sonuçları

Bu senaryoda LSTM ve GRU modellerinde eğitim ilerledikçe train loss düşmeye devam ederken validation loss'un yükselmesi, belirgin bir overfitting davranışına işaret etmiştir. Özellikle GRU modelinde en iyi epoch değerinin 3 olması, modelin çok erken aşamada validation performansını kaybetmeye başladığını göstermektedir. Transformer modeli ise daha dengeli bir öğrenme eğrisi üretmiş ve uzun tahmin ufkunda recurrent modellere kıyasla daha stabil bir genelleme davranışı sergilemiştir. Bu durum, Transformer mimarisinin uzun horizon forecasting problemlerinde neden daha sık tercih edildiğini destekleyen bir bulgu olarak değerlendirilebilir.

4.2. Genel Yorum

Elde edilen sonuçlar birlikte değerlendirildiğinde, kısa vadeli tahminde (**pred_len=1**) LSTM modelinin en yüksek doğruluğu sağladığı görülmektedir. GRU modeli ise daha az parametre ile LSTM'e oldukça yakın performans üretmiş, bu nedenle daha hafif bir alternatif olarak öne çıkmıştır. Transformer modeli kısa vadeli tahminde recurrent modellere göre geride kalmıştır.

Buna karşılık tahmin ufkı 24 saate çıkarıldığında modellerin davranışı değişmiştir. Recurrent tabanlı modellerde overfitting daha belirgin hale gelirken, Transformer modeli daha dengeli bir öğrenme süreci göstermiştir. Bu sonuç, model seçiminin yalnızca hata metriklerine göre değil, aynı zamanda tahmin ufkı, model karmaşıklığı ve genelleme davranışı birlikte değerlendirilerek yapılması gerektiğini göstermektedir.

5. Veri Seti ve Literatür Araştırması

Veri Seti

Bu çalışmada kullanılan veri seti **ETTh1** veri setidir. ETTh1, elektrik transformatörüne ait saatlik ölçümler içeren bir zaman serisi veri setidir. Veri setinde birden fazla giriş değişkeni bulunmakta olup hedef değişken olarak **OT (oil temperature)** kullanılmıştır. Yağ sıcaklığı, transformatörün çalışma durumu ve güvenilirliği açısından kritik bir gösterge olduğu için, bu değerin doğru tahmini güç sistemleri açısından önem taşımaktadır. Transformer oil temperature prediction probleminin literatürde de önemli bir araştırma alanı olduğu görülmektedir.

1. Veri Seti İçeriği:

- o Veri seti, elektrik transformatörüne ait saatlik ölçümlerden oluşmaktadır.
- o Veri setinde birden fazla giriş değişkeni yer almakta, hedef değişken olarak ise **OT (oil temperature)** kullanılmaktadır.
- o Çalışmada amaç, geçmiş zaman adımlarındaki veriler kullanılarak bir sonraki zaman adımındaki OT değerinin tahmin edilmesidir.

2. Veri Hazırlama ve Ayrıştırma:

- o Veri zaman sırasına göre düzenlenmiştir.
- o Eksik değerler kontrol edilmiş, gerekli durumlarda doldurma işlemi uygulanmıştır.
- o Veri, **train / validation / test** olacak şekilde ayrılmıştır.
- o Ölçekleme işlemi için **StandardScaler** kullanılmıştır.

o **Sliding window** yöntemi ile geçmiş **96 saatlik** veriler giriş, sonraki **1 saatlik OT değeri** ise çıktı olacak şekilde örnekler oluşturulmuştur.

o Elde edilen veri yapısı X_train, X_val, X_test, y_train, y_val, y_test dosyaları olarak kaydedilmiş ve tüm modeller aynı veri yapısı ile eğitilmiştir.

Bu yapı sayesinde modeller aynı ön işleme adımları ile hazırlanmış veri üzerinde eğitilmiş ve performans karşılaştırması daha adil hale getirilmiştir.

Literatür Araştırması

Çalışmada kullanılan LSTM, GRU ve Transformer tabanlı modeller ile zaman serisi tahmini problemi hakkında bilgi edinmek amacıyla aşağıdaki literatür taramaları yapılmıştır:

1. Haoyi Zhou, Shanghang Zhang, Jieqi Peng, Shuai Zhang, Jianxin Li, Hui Xiong, Wancai Zhang, “Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting”

o Informer modelinin uzun zaman serisi tahmini problemlerinde klasik Transformer yapısına göre nasıl daha verimli hale getirildiğini açıklayan çalışma. Transformer tabanlı yaklaşımın teorik temelini desteklemektedir.

2. Haomin Chen, Lingwen Meng, Yu Xi, Mingyong Xin, Siwu Yu, Guangqin Chen ve Yumin Chen, “GRU Based Time Series Forecast of Oil Temperature in Power Transformer”

o Güç transformatörlerinde yağ sıcaklığı tahmini için GRU tabanlı bir yöntem öneren çalışma. GRU mimarisinin bu problem için uygunluğunu desteklemektedir.

3. Haomin Chen, Lingwen Meng, Yu Xi, Changbao Xu, Yu Wang, Mingyong Xin, Guangqin Chen ve Yumin Chen, “Power Transformer Oil Temperature Prediction Based on Empirical Mode Decomposition-Bidirectional Long Short-Term Memory”

o ETT-small veri seti üzerinde yağ sıcaklığı tahmini yapan ve BiLSTM tabanlı yaklaşımı kullanan çalışma. Problem alanının literatürde yerleşik olduğunu göstermektedir.

4. Mobarak Abumohsen, Amani Yousef Owda ve Majdi Owda, “Electrical Load Forecasting Using LSTM, GRU, and RNN Algorithms”

o Elektrik yük tahmininde LSTM, GRU ve RNN modellerini karşılaştıran çalışma. GRU’nun güçlü bir alternatif olduğunu göstermesi açısından önemlidir.

5. Ariana Yunita, MHD Iqbal Pratama, Muhammad Zaki Almuzakki ve diğerleri, “Performance Analysis of Neural Network Architectures for Time Series Forecasting: A Comparative Study of RNN, LSTM, GRU, and Hybrid Models”

o Farklı zaman serisi veri setlerinde RNN, LSTM, GRU ve hibrit modellerin performansını karşılaştıran çalışma. Model başarısının veri setine göre değişebileceğini göstermektedir.

6. Paul Bilokon ve Yitao Qiu, “Transformers versus LSTMs for Electronic Trading”

o Transformer ve LSTM tabanlı modellerin farklı görevlerde her zaman aynı performansı göstermediğini inceleyen çalışma. Sonuçların veri yapısına bağlı olarak değişebileceğini desteklemektedir.

7. Pengfei He, Linge Li, Chao Mu, Jiyu Wang ve Xiaoqin Liu, “Improved LSTM Transformer Oil Temperature Prediction Model Based on Fourier Transform”

o Yağ sıcaklığı tahmininde hibrit ve dönüşüm tabanlı yöntemlerin kullanılabilirliğini gösteren çalışma. Alanın gelişmiş yöntemlerle de ele alındığını göstermektedir.

6. Referanslar

1. Yunita, A., Pratama, M. I., Almuzakki, M. Z., Ramadhan, H., Akhir, E. A. P., Mansur, A. B. F., & Basori, A. H. (2025). Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models. *MethodsX*, 15, 103462.
2. Bilokon, P., & Qiu, Y. (2023). Transformers versus LSTMs for electronic trading. *arXiv preprint arXiv:2309.11400*.
3. Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021, May). Informer: Beyond efficient transformer for long sequence time-series forecasting. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 35, No. 12, pp. 11106-11115).
4. Chen, H., Meng, L., Xi, Y., Xin, M., Yu, S., Chen, G., & Chen, Y. (2023). Gru based time series forecast of oil temperature in power transformer. *Distributed Generation & Alternative Energy Journal*, 393-412.
5. He, P., Li, L., Mu, C., Wang, J., & Liu, X. (2025). Improved LSTM transformer oil temperature prediction model based on Fourier Transform. *Systems Science & Control Engineering*, 13(1), 2530109.
6. Chen, H., Meng, L., Xi, Y., Xu, C., Wang, Y., Xin, M., ... & Chen, Y. (2023). Power transformer oil temperature prediction based on empirical mode decomposition-bidirectional long short-term memory. *Journal of algorithms & computational technology*, 17, 17483026231176196.
7. Abumohsen, M., Owda, A. Y., & Owda, M. (2023). Electrical load forecasting using LSTM, GRU, and RNN algorithms. *Energies*, 16(5), 2283.